

PROJETO FINAL DA TRILHA DE CIÊNCIA DE DADOS

Desafio: Classificação de Score de Crédito com Machine Learning

Fintech fictícia: Data Girls Finance

Cientista de Dados: Jessica Pereira

1. Objetivo do Projeto

O objetivo deste projeto foi desenvolver um modelo preditivo de Machine Learning para automatizar e otimizar a classificação de score de crédito de clientes da *Data Girls Finance*. Buscou-se substituir análises manuais inconsistentes por uma solução escalável, capaz de identificar perfis de risco (*Poor*, *Standard*, *Good*) e reduzir a inadimplência sem prejudicar a experiência dos bons pagadores.

2. Etapas do Pipeline Desenvolvido

- **Leitura e Tratamento de Dados:** Identificação de ruídos (como caracteres _ e strings misturadas em colunas numéricas), correção de outliers (como idades inválidas ou números de contas impossíveis) e imputação de valores nulos utilizando a mediana geral das variáveis.
- **Análise Exploratória (EDA):** Investigação visual do comportamento financeiro através de gráficos de distribuição, boxplots de renda e distribuição de histórico de atrasos.
- **Preparação dos Dados:** Codificação de variáveis textuais usando *LabelEncoder* e separação dos dados em Treino (80%) e Teste (20%) de forma estratificada para manter a proporção das classes.
- **Modelagem e Avaliação:** Treinamento comparativo entre os algoritmos *Random Forest* e *XGBoost*, seguido por análises detalhadas de relatórios de métricas e matrizes de confusão.

3. Escolha do Modelo Final

O modelo escolhido para entrar em produção na esteira de crédito foi a **Random Forest**. Ela apresentou uma acurácia geral superior (**79%** contra 75% do *XGBoost*) e demonstrou maior segurança para o negócio ao obter um *Recall* de **72%** na classe de maior risco (*Poor*), minimizando a liberação de crédito para perfis inadimplentes.

4. Respostas às Perguntas Norteadoras de Negócio

- **Quais variáveis têm maior relação com a capacidade de pagamento dos clientes?**

Com base no gráfico de importância de variáveis desenvolvido no projeto, as variáveis com maior impacto na decisão são Delay_from_due_date (Dias médios de atraso desde o vencimento) e Num_of_Delayed_Payment (Número de pagamentos atrasados). O histórico comportamental de pontualidade provou-se muito mais decisivo para prever o risco do que a renda isolada do cliente.

- **Qual perfil de cliente possui maior probabilidade de ser classificado com score “Poor”?**

O perfil crítico de alto risco mapeado na análise exploratória é composto por clientes que apresentam, simultaneamente: média de atraso superior a 15-20 dias no vencimento das parcelas, histórico com alto número de pagamentos em atraso recorrentes e uma taxa elevada de endividamento acentuado (Outstanding_Debt).

- **Um modelo de Machine Learning consegue classificar o score de crédito com boa performance?**

Sim. Atingir 79% de acurácia com um modelo de baseline em um dataset altamente ruidoso e complexo demonstra que algoritmos supervisionados conseguem capturar com segurança os padrões de risco, tornando o processo de decisão muito mais rápido, padronizado e justo do que a revisão manual de propostas.

- **Como os resultados do modelo apoiam a equipe de crédito na concessão e revisão de limites?**
 - *Esteira de Concessão Automatizada:* Clientes classificados como Good podem receber aprovação instantânea de crédito. Propostas classificadas como Poor podem ser recusadas automaticamente ou direcionadas para uma mesa de auditoria humana rigorosa.
 - *Gestão de Limites:* Clientes que o modelo aponta transição positiva de score podem receber aumentos proativos de limite. Já os clientes identificados com tendência de queda de score podem ter seus limites reduzidos preventivamente para mitigar riscos de superendividamento.
- **Quais cuidados éticos e de negócio devem ser considerados antes do modelo ir para produção?**
 - *Evitar Vieses Discriminatórios:* Garantir que o modelo não utilize ou crie correlações indiretas com variáveis não financeiras para punir grupos historicamente vulneráveis.
 - *Direito à Explicabilidade:* O cliente tem o direito de entender o motivo de uma negativa de crédito. Por isso, no futuro, recomenda-se o uso de ferramentas de interpretabilidade (como o SHAP) para mapear o peso de cada decisão do modelo.
 - *Monitoramento de Data Drift:* O comportamento do mercado muda devido a fatores macroeconômicos. O modelo precisará ser monitorado e retreinado periodicamente para que suas regras de corte não fiquem obsoletas.

5. Recomendações Práticas para a Data Girls Finance

1. Implementar o algoritmo Random Forest na esteira principal de análise como primeiro filtro automatizado de triagem de propostas.
2. Criar alertas e réguas de cobrança preventiva para clientes cujos indicadores de dias de atraso (Delay_from_due_date) comecem a subir nas bases internas, agindo antes do cliente se tornar efetivamente inadimplente.

3. Desenvolver uma política transparente de orientação de score, explicando aos clientes negados quais hábitos financeiros (ex: reduzir dias de atraso) eles precisam adotar para ter o crédito aprovado em consultas futuras.